LG aimers

MQL 데이터 기반 B2B 영업기회 창출 예측 모델 개발

발표자 진욱부승

목차

EDA

- 도메인 분석
- 데이터 전처리 방법
- Feature selection

Modeling

- 모델 소개 및 선택
- 하이퍼파라미터 설정
- 최종 F1 score

향후 계획

- 본선에서 해볼 전략 및 방법론

01

EDA

도메인 분석 - B2B

도메인 분석

B2B는 Business-to-Business의 약자로, 기업 간의 거래를 의미

01 EDA

데이터 전처리

```python
# 범주형 변수 결측치 처리
cat_features=[1,4,5,9,10,11,12,14,15,21,22,23,24]

for idx in cat_features:
    x_train.iloc[:, idx].fillna('none', inplace=True)
    x_val.iloc[:, idx].fillna('none', inplace=True)

# 수치형 변수 결측치 처리
nantozero=[6,7,8]
for idx in nantozero:
    x_train.iloc[:, idx].fillna(0, inplace=True)
    x_val.iloc[:, idx].fillna(0, inplace=True)
```

범주형/ 수치형 데이터 전처리

범주형 데이터의 결측치는 ‘none’ 값으로 처리

수치형 데이터의 결측치는 0값으로 처리하였다.

모델 소개

CatBoost

범주형 변수가 많은 데이터셋에 좋은 모델!!

범주형 변수 처리 방식
1. Response encoding
2. Categorical Feature Combination

장점
1. 학습 속도가 빨라 상용화에 좋음
2. 범주형 변수가 많은 데이터에 효과적

02 Modeling

Hyper parmeter 설정

클래스 불균형을 해소하기 위해 가중치를
전환여부 값의 false에 해당하는 것에 11.5를 부여

과적합 방지를 위해 od_wait = 50, l2_leaf_reg =3으로 설정

```
model = CatBoostClassifier(
    iterations=2000,  # 더 단
    learning_rate=0.05,  # 학
    depth=6,  # 트리의 깊이를
    l2_leaf_reg=3,  # L2 정규
    eval_metric='AUC',  # 이
    border_count=254,  # 기본
    random_seed=42,  # 결과의
    verbose=100,  # 학습 과정
    use_best_model=True,  #
    od_type='Iter',  # 반복이
    od_wait=50,# 지정된 반복
    class_weights= [1,11.5]
```

02 Modeling

최종 F1-score 결과

자체적으로 나눈 Train/val 에서 Val 데이터에 대한 f1-score 와 혼동행렬은 오른쪽 그림과 같다.

```
오차행렬:
 [[  909    76]
 [  490 10385]]

정확도: 0.9523
정밀도: 0.6497
재현율: 0.9228
F1: 0.7626
```

실제 Test 데이셋의 F1-Score 결과는 0.7772 이다.

03 향후 계획

개선 방법론

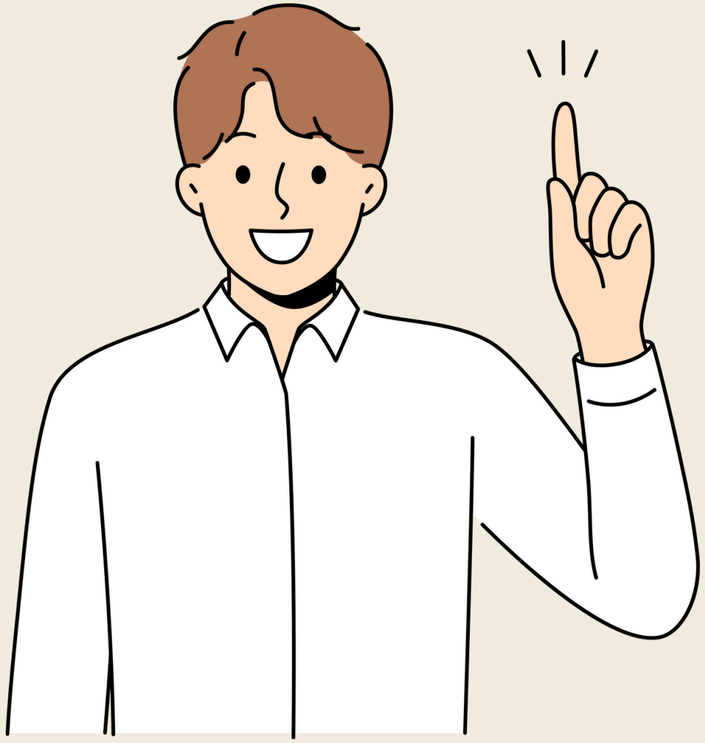

- 모델 변경 (분류->딥러닝 회귀 모델)
- 임베딩 모델 성능 높이기
- 도메인 지식을 이용한 가공 변수 생성

*

Q&A

질문 및 토론

발표를 마치고 질문을 받거나 토론할 시간을 마련합니다.

감사합니다

THANK YOU